

Desafio Técnico Prático: Analytics Engineering

Modelagem Dimensional, Transformação de Dados, FinOps & Governança em Cloud Data Warehouse

1. Contexto de Negócio

Você está assumindo o papel de liderança técnica em Analytics Engineering em uma grande rede integrada de saúde e medicina diagnóstica. Atualmente, a empresa realiza milhares de consultas e exames laboratoriais/imagem por dia.

Os dados chegam desnormalizados de múltiplos sistemas de agendamento e faturamento. A diretoria e as áreas de negócio relatam dificuldades com relatórios lentos, custos elevados de consultas em Cloud DW, divergências em relatórios financeiros e falta de rastreabilidade histórica sobre alterações cadastrais e planos de saúde dos pacientes.

Instruções e Prazo de Entrega:

- **Prazo:** Conforme alinhado com o time de Recrutamento (estimativa de esforço: 3 a 4 horas).
- **Formato de Envio:** Link de repositório Git (GitHub, GitLab, etc.) ou arquivo compactado (.zip) contendo os códigos, DDLs, documentação e justificativas técnicas.
- **Apresentação Técnica:** Sessão de 30 a 45 minutos com a equipe técnica para defender suas escolhas de arquitetura, modelagem e boas práticas.

2. Dados Disponibilizados (Camada Raw)

Para a execução deste desafio, você tem acesso a 3 arquivos em formato CSV simulando a camada bruta:

A. raw_atendimentos.csv

Registros de atendimentos gerais (consultas ou realização de baterias de exames).

Campo	Tipo	Descrição
id_atendimento	VARCHAR	Identificador único do atendimento.
id_paciente	VARCHAR	Identificador do paciente (chave de ligação).
data_hora_atendimento	TIMESTAMP	Data e hora da realização do atendimento.
tipo_atendimento	VARCHAR	Categoria: 'Consulta Eletiva', 'Pronto Atendimento', 'Exame Diagnóstico', etc.
id_unidade	VARCHAR	Código da unidade de atendimento.
status	VARCHAR	Status do atendimento ('Concluído', 'Cancelado', 'Em Andamento').
valor_bruto	NUMERIC	Valor total bruto somado dos procedimentos do atendimento.
desconto	NUMERIC	Desconto total concedido no atendimento.
valor_liquido	NUMERIC	Valor final a faturar (valor bruto - desconto).

B. raw_procedimentos_itens.csv

Detalhamento de cada exame ou consulta médica executada dentro de um atendimento.

Campo	Tipo	Descrição
id_item	VARCHAR	Identificador único do item no atendimento.
id_atendimento	VARCHAR	Chave estrangeira vinculando ao atendimento.
codigo_procedimento	VARCHAR	Código padronizado do procedimento (ex: PRC_001).
nome_procedimento	VARCHAR	Nome do procedimento (ex: Hemograma Completo, Ressonância Magnética).
id_medico_executante	VARCHAR	Identificador do médico/especialista executante.
valor_item	NUMERIC	Valor individual do procedimento na tabela de preços.

C. raw_cadastro_pacientes.csv

Log histórico de cadastros e atualizações dos pacientes (ex: mudança de plano de saúde ou cidade).

Campo	Tipo	Descrição
id_paciente	VARCHAR	Identificador único do paciente.
nome	VARCHAR	Nome completo do paciente.
plano_saude	VARCHAR	Plano / Convênio vigente no momento da atualização.
cidade	VARCHAR	Cidade de residência informada.
data_atualizacao	TIMESTAMP	Momento em que a alteração cadastral foi registrada.

3. Escopo do Desafio (Entregáveis)

Parte 1: Modelagem Dimensional & Arquitetura de Dados

A partir dos dados fornecidos, estruture a modelagem dimensional (Kimball) para a camada analítica / Data Mart:

- Apresente o desenho (diagrama ER ou descritivo) das **Tabelas Fato e Dimensões**.
- Defina com clareza a granularidade de cada fato proposta.
- Implemente a estratégia de **SCD (Slowly Changing Dimension) Tipo 2** para a dimensão de pacientes, garantindo que um atendimento histórico mantenha o plano de saúde vigente na data em que o procedimento foi realizado.
- Defina o uso e a geração de **Surrogate Keys (SKs)** no modelo.

Parte 2: Pipelines de Transformação & Qualidade de Dados (Data Quality)

Construa os scripts SQL (ou projeto em **Dataform** / **dbt**):

- Scripts DDL e DML/CTEs criando a camada dimensional tratada e limpa.
- Implementação do cálculo do valor líquido por item de procedimento (rateio proporcional de descontos).
- Implementação de **testes automatizados de qualidade de dados** (ex: validação de chaves primárias únicas, integridade referencial, campos *not null* e consistência de valores monetários).

Parte 3: Performance, Arquitetura Cloud & FinOps

Responda às seguintes questões técnicas de arquitetura:

- **Google BigQuery:** Qual a sua estratégia de **particionamento** e **clustering** para as tabelas fato e dimensões? Justifique como sua escolha otimiza os custos de leitura (bytes escaneados) e acelera as consultas mais comuns do BI.
- **Snowflake:** Se a mesma arquitetura fosse implementada em Snowflake, como você configuraria os *Virtual Warehouses* (tamanho, políticas de auto-suspend e multi-cluster) para separar cargas de transformação pesadas de consultas ad-hoc da diretoria?

Parte 4: DevOps, CI/CD & Governança

Descreva ou forneça um exemplo de configuração (ex: pipeline .yaml para Azure DevOps ou GitHub Actions):

- Como garantir que alterações no código SQL passem por validações automatizadas antes de chegar em produção (estratégia de *Slim CI* ou ambientes isolados)?
- Como você estruturaria o versionamento, estratégia de branches e a documentação do catálogo de dados para o restante do time?